

رگرسیون


مهدي شكري زاده



معرفی مسئله رگرسیون

□ رگرسیون خطی تک متغیره

○ ارتباط بین داده های خروجی و داده های ورودی توسط یک مدل خطی قابل توصیف است.



$$y(x) = wx + w_0$$

Single parameter linear regression

inputs	outputs
$x_1 = 1$	$y_1 = 1$
$x_2 = 3$	$y_2 = 2.2$
$x_3 = 2$	$y_3 = 2$
$x_4 = 1.5$	$y_4 = 1.9$
$x_5 = 4$	$y_5 = 3.1$

○ هدف تعیین پارامترهای مدل بر اساس داده های در دسترس است.

رگرسیون خطی - تک متغیره

□ مدل رگرسیون خطی برای مسئله عنوان شده به شکل ساده یک خط به صورت زیر قابل توصیف است:

$$\underbrace{\{x_i, y_i\}_i}_{\text{Given dataset}} \longrightarrow y_i(x) = WX_i + n_i, W = [w \quad w_0], X_i = \begin{bmatrix} x_i \\ 1 \end{bmatrix}$$

○ که در آن n_i یک فرآیند سفید گوسی مستقل با میانگین 0 و واریانس نامعلوم است.

□ مسئله:

○ برای چه مقداری از بردار وزن های W احتمال رخداد زوج داده های $\{x_i, y_i\}_i$ بیشینه است؟

$$W^* = \arg \max \prod_{i=1}^N P(y_i | x_i, W)$$

رگرسیون خطی - تک متغیره

□ توزیع شرطی داده های خروجی به شرط داده های ورودی و بردار وزن ها یک توزیع نرمال است. (چرا؟)

$$\prod_{i=1}^N P(y_i | x_i, W) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y - WX_i)^2}{2\sigma^2}\right)$$

○ به منظور تاثیر تمام نقاط داده شده، negative-log تابع فوق کمینه می شود. (چرا؟)

○ مسئله بهینه سازی جدید دارای پاسخ یکسان با مسئله اصلی است. (چرا؟)


$$W^* = \arg \min -\log \prod_{i=1}^N P(y_i | x_i, W) \quad \longrightarrow \quad W^* = \arg \min \sum_{i=1}^N (y - WX_i)^2$$

Least square problem \longleftarrow Sum Squared Error (SSE)

رگرسیون خطی - تک متغیره

□ بردار پارامترهایی که رخداد داده های خروجی به شرط داده های ورودی را بیشینه می کند پاسخ مسئله بهینه سازی حداقل مربعات است.

$$W^* = \operatorname{argmin} \sum_{i=1}^N (y - WX_i)^2 \longrightarrow W^* = \frac{\sum_{i=1}^N y_i X_i}{\sum_{i=1}^N |X_i|^2}$$




□ آیا می توان واریانس نویز را تخمین زد؟


رگرسیون خطی - مثال

□ داده ها توسط یک خط با شیب 2 و عرض از مبدا 0 تولید شده اند

$$W^* = 2.03, \quad \sigma = 1$$



$$W^* = 2.1, \quad \sigma = 8$$



رگرسیون خطی - چند متغیره

□ رابطه بیان شده برای رگرسیون خطی تک متغیره، به صورت زیر قابلیت تعمیم دهی به حالت چند متغیره را داراست.

$$y(x) = w_0 + w_1x_1 + w_2x_2 + \cdots + w_Dx_D$$

□ پارامترهای مدل در این حالت مشابه حالت اسکالر تخمین زده میشوند:

$$Y = XW + n, Y = \begin{bmatrix} y_1(x) \\ \vdots \\ y_n(x) \end{bmatrix}_{n \times 1}, X = \begin{bmatrix} 1 \\ x_1 \\ \vdots \\ x_D \end{bmatrix}_{n \times (D+1)}^T, W = \begin{bmatrix} w_0 \\ \vdots \\ w_D \end{bmatrix}_{(D+1) \times 1}$$

$$W^* = (X^T X)^{-1} X^T Y$$

رگرسیون خطی با نویز متغیر

□ اگر نویز خروجی اضافه شده دارای مشخصات آماری متغیر با زمان باشد، مدل رگرسیون خطی توسعه داده شده دارای بایاس است. (چرا؟)

○ برای مسئله تک متغیره


$$W^* = \operatorname{argmin} \sum_{i=1}^N \frac{(y - WX_i)^2}{\sigma^2} \quad \longrightarrow \quad W^* = \operatorname{argmin} \sum_{i=1}^N \frac{(y - WX_i)^2}{\sigma_i^2}$$

Weighted Least Square (WLS) ← Weighted Sum square error

$$W^* = \frac{\sum_{i=1}^N \frac{y_i X_i}{\sigma_i}}{\sum_{i=1}^N \frac{|X_i|^2}{\sigma_i}} \quad \text{For Gaussian colored noise}$$

رگرسیون خطی با نویز متغیر

□ هر نمونه متناسب با نویزی که می گیرد وزن دهی می شود.




$$W^* = (X^T Q^{-1} X)^{-1} X^T Q^{-1} Y, \quad Q^{-1} = \begin{pmatrix} \frac{1}{\sigma_1^2} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1/\sigma_n^2 \end{pmatrix}$$

For multivariate case

رگرسیون غیرخطی

□ داده های زیر را در نظر بگیرید:

x_i	y_i
$1/2$	$1/2$
1	2.5
2	3
3	2
3	3



$$y_i(x_i) = \sqrt{w + x_i} + n_i$$

$$w^* = \arg \min \sum_{i=1}^N (y_i - \sqrt{w + x_i})^2$$

For white Gaussian noise

□ حل بسته ریاضی برای مسئله فوق وجود ندارد. (چرا؟) راه حل چیست؟

Numerical Optimization

رگرسیون غیرخطی

□ در بسیاری از موارد تابع هزینه بدست آمده برای مسئله رگرسیون غیرخطی محدب نیست.
(با فرض شناخته بودن ارتباط ورودی و خروجی)

□ نگاشت فضای ورودی

- ارتباط بین ورودی و خروجی در فضای داده های در دسترس خطی نیست.
- فضای ورودی داده ها را به فضایی نگاشت می دهیم تا ارتباط بین ورودی و خروجی خطی شود (یا با خط قابل تقریب باشد)

$$y(x) = w_0 + w_1\phi_1(x_1) + w_2\phi(x_2) + \cdots + w_D\phi(x_D)$$

رگرسیون غیرخطی

□ نگاشت فضای ورودی

$$y(x) = w_0 + w_1\phi_1(x_1) + w_2\phi(x_2) + \dots + w_D\phi(x_D)$$

- کلیه مطالب ذکر شده بر اساس فضای ورودی قابل تعمیم دهی به فضای جدید هستند.

□ نگاشت های رایج

- چند جمله ای
- توابع شعاعی پایه
- تبدیلات مختلف بر روی فضای ورودی (تبدیل فوریه، تبدیل موجک، و ...)

رگرسیون چندجمله ای

□ رابطه بین ورودی و خروجی توسط یک چند جمله ای مشخص می شود

○ مدل رگرسیون چندجمله ای درجه 2 برای یک متغیر

$$y(x) = w_0 + w_1x + w_2x^2 + w_3x^3 + \dots + w_nx^n$$

□ برای حالت چند متغیر مدل چند جمله ای از بسط نیوتن محاسبه می شود

○ مدل رگرسیون چندجمله ای درجه 2 برای دو متغیر



$$y(x) = w_0 + w_1x_1 + w_2x_2 + w_3x_1^2 + w_4x_2^2 + w_5x_1x_2$$

○ آیا می توان از مدل های فوق برای رگرسیون خطی استفاده کرد؟

توابع پایه شعاعی

□ این توابع عمدتاً برای سنجش فاصله مورد استفاده قرار می‌گیرند. بنابراین مدل بدست آمده بر اساس فاصله نقاط فضای ورودی از مرکز این توابع است.

$$y(x) = 2\phi_1(x) + 0.05\phi_2(x) + 0.5\phi_3(x)$$




□ پارامترهای کرنل چگونه تعیین می‌شوند؟

□ در فضای n بعدی توصیف این توابع به چه شکل است؟


رگرسیون مقاوم

□ وجود داده های پرت چه تاثیری بر مدل خواهند داشت؟




رگرسیون مقاوم

- مدل سازی رگرسیون بر اساس فرض نرمال بودن نویز انجام شده است که نسبت به داده های پرت حساسیت بالایی دارد.
- یک راه حل استفاده از توزیع های long tail است.



LS for Laplacian noise



رگرسیون مقاوم

❑ مشکلی که فرض نرمال بودن نویز ایجاد می کند، هم ارز کردن تابع بیشینه شباهت با تابع هزینه حداقل مربعات است.

○ در صورتی که داده پرت وجود داشته باشد، مربع فاصله این داده تا منحنی برازش شده باعث افزایش تابع هزینه خواهد شد.

○ یک راه حل استفاده از تابع هزینه Huber است.

○ حل این مسئله سریعتر از فرض توزیع لاپلاس برای نویز است


$$L_H(r, \delta) = \begin{cases} \frac{r^2}{2}, & |r| \leq \delta \\ \delta|r| - \frac{\delta^2}{2}, & |r| > \delta \end{cases}$$

رگرسیون مقاوم

□ رویکرد ساده دیگری نیز وجود دارد که نیازی به تغییر تابع هزینه و یا فرضیات مسئله ندارد.

○ استفاده از کرنل برای وزن دهی بردار خطا

$$\alpha_k = \exp(-(y_k - y_{est})^2)$$



□ الگوریتم:

- تخمین حداقل مربعات بر اساس داده های موجود
- تعیین بردار تخمین خروجی y_{est} بر اساس مدل آموزش دیده شده
- تشکیل بردار وزن بر اساس بردار تخمین زده شده α_k
- تکرار مرحله 1 با بردار خروجی $\alpha_k y_k$

بیش برازشی در مدل رگرسیون

□ همانطور که گفته شد، برای یک مدل رگرسیون بردار پارامترها به نحوی تعیین می شود تا احتمال تولید دنباله ورودی و خروجی بر اساس داده های داده شده پیشینه شود.

تکرار آزمایش	پیشامد
1	رو
2	رو
.	.
.	.
.	.
100	رو



○ مسئله پرتاب سکه را در نظر بگیرید:

○ اگر سکه را برای بار 101 ام پرتاب کنیم، بر اساس مشاهدات بدست آمده چه پیشامدی رخ خواهد داد؟

○ آیا نتیجه آزمایش با دانش پیشین ما از پرتاب سکه همخوانی دارد؟

○ برای جلوگیری از مسئله بیش برازش، نیاز داریم تا عدم قطعیت ناشی از آزمایش را نیز در مدل سازی دخیل کنیم.


بیش برازشی در مدل رگرسیون

□ در مدل های یادگیری ماشین بیش برازشی به دلایل زیر اتفاق می افتد:


○ تعداد ناکافی داده ها در فاز آموزش مدل

○ پیچیدگی مدل

رگرسیون چند جمله ای با درجه 3



رگرسیون چند جمله ای با درجه 9



از دیدگاه آماری، بیش برازشی یک مدل، هم ارز افزایش واریانس تخمین است

تنظیم کنندگی مدل Regularization

افزودن نویز خروجی ☐

- این اقدام هم ارز لحاظ کردن مقدار عدم قطعیت در برچسب داده هاست.

جمع آوری داده ☐

- داده های حجیم نقش تنظیم کنندگی در مدل را دارند.
- در شرایطی که داده های زیادی در دست باشد، رویکرد بیشینه شباهت قابلیت تعمیم دهی مدل را افزایش می دهد

تنظیم کنندگی مدل Regularization

□ رویکرد بیزین

$$y(x) = W^T \phi(x) + n \rightarrow \underbrace{P(y(x)|W)}_{\text{Evidence}}, \underbrace{P(W)}_{\text{Prior}}$$

- توزیع پارامترها هر توزیع دلخواهی می تواند باشد (بر اساس دانش ما از مسئله تعیین می شود)

$$P(Y, W) = P(Y|W)P(W) \rightarrow W^* = \arg \max \log P(Y, W) \quad \text{Maximum a Posterior}$$

□ بهترین توزیع پیشین

- خانواده توزیع های نمایی

تنظیم کنندگی مدل Regularization

□ تنظیم کنندگی بر اساس نرم - 2 پارامترها

$$y(x) = W^T \phi(x) + n \rightarrow P(y(x)|W) \sim N(W^T \phi(x), \sigma^2), P(W) \sim N(\mu, \sigma_w^2)$$

○ اگر میانگین توزیع پیشین را صفر در نظر بگیریم:

$$W^* = \operatorname{argmin} \sum_{i=1}^N (y - WX_i)^2 + \underbrace{\frac{\sigma^2}{\sigma_w^2}}_{\lambda} |W|^2$$

L2 Regularization (Ridge Regression)

○ مسئله فوق را می توان به صورت یک مسئله بهینه سازی مقید بیان کرد (چگونه؟)

○ رابطه بردار وزن ها چگونه محاسبه می شود؟

تنظیم کنندگی مدل Regularization

□ تنظیم کنندگی بر اساس نرم - 1 پارامترها

$$y(x) = W^T \phi(x) + n \rightarrow P(y(x)|W) \sim N(W^T \phi(x), \sigma^2)$$

○ اگر توزیع پیشین پارامترها را یک توزیع لاپلاس با مقدار پارامتر location صفر فرض کنیم:


$$W^* = \operatorname{argmin} \sum_{i=1}^N (y - WX_i)^2 + \lambda |W| \quad \text{L1 Regularization}$$

○ مسئله فوق را می توان به صورت یک مسئله بهینه سازی مقید بیان کرد (چگونه؟)

تنظیم کنندگی - دید هندسی

$$W^* = \operatorname{argmin} \sum_{i=1}^N (y - WX_i)^2$$

کانتورهای سطوح ثابت تابع هزینه (?)



□ کدام مدل بهتر است؟

□ از کدام مدل می توان به عنوان مدل انتخاب ویژگی استفاده کرد؟

حداقل مربعات گام به گام

□ پاسخ مسئله حداقل مربعات چند متغیره به تابع هزینه حداقل مربعات به صورت زیر محاسبه شد:

$$W^* = (X^T X)^{-1} X^T Y$$

□ اگر ابعاد ماتریس X بزرگ باشد، اپراتور معکوس گیری با مشکلات زمانی جدی مواجه خواهد شد. راه حل چیست؟

- الگوریتم های آنلاین آموزش – گرادیان نزولی
- پاسخی که الگوریتم گرادیان نزولی برای مسئله رگرسیون با فرضیات داده شده بدست می دهد یک بهینه سراسری است (چرا؟)